5

Jak radzić sobie z brakującymi wartościami?

Brakujące wartości

Pola, w których nie ma danych.

Przyczyny:

- błąd przy wprowadzaniu danych,
- ochrona prywatności,
- brak odpowiedzi w ankiecie,
- problemy techniczne przy zbieraniu danych.

Jeden z najczęstszych problemów i kluczowy etap przetwarzania wstępnego.

```
# Czy są braki? (isna == isnull)
titanic.isna()

# Liczba braków w kolumnach
titanic.isna().sum()

# Procent braków
titanic.isna().mean() * 100

# Łączna liczba braków
titanic.isna().sum().sum()
```

Czym jest NaN i dlaczego jest wyjątkowy?

- **NaN** (*Not a Number*) — specjalna wartość oznaczająca brak danych.
- `NaN` nie jest równy niczemu — nawet sobie. Dlatego do wykrywania braków służą funkcje `isna()`.
- `0` i pusty napis `""` to dla pandas **zwykłe wartości**, a nie braki.

```
np.nan == np.nan      # False (!)
pd.isna(np.nan)       # True

df = pd.DataFrame({
    "A": [1, np.nan, 3],    # NaN  — brak
    "B": [4, None, 6],      # None — też brak
    "C": [7, 0, 9],         # 0    — NIE brak!
    "D": ["x", "", "z"],    # ""   — NIE brak!
})
df.isna().sum()     # A: 1, B: 1, C: 0, D: 0
```

Braki „w przebraniu”

`isna()` widzi tylko `NaN`/`None`. Braki bywają zapisane jako tekst (`"NA"`, `"brak"`, `"?"`, `"-"`) lub liczba (`0`, `-1`, `-999`):

```
# Podejrzane wartości w kolumnie liczbowej
(titanic["Fare"] == 0).sum()      # 15

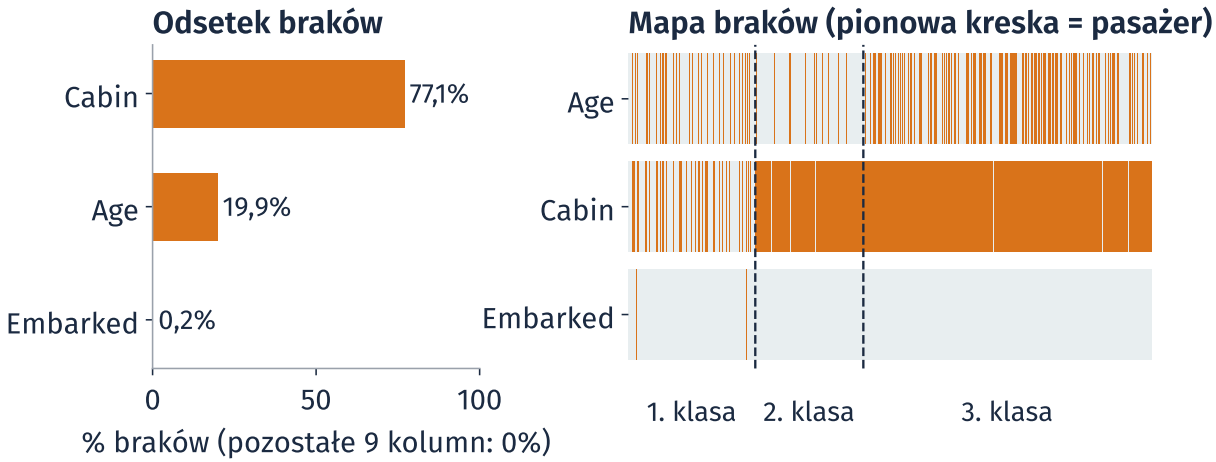
# Napisy udające brak
df["kolumna"].value_counts()       # "?", "-", "brak"...

# Przy wczytywaniu…
pd.read_csv("plik.csv", na_values=["brak", "?", -999])
# …albo po wczytaniu
df = df.replace(["?", "-", -999], np.nan)
```

Pytanie do sali

15 pasażerów Titanica ma bilet za 0 £. To brak danych, błąd czy prawda (np. bilet służbowy)? Jak to sprawdzić?

Gdzie są braki?




```
braki = titanic.isna()
# odsetek braków
braki.mean().sort_values().plot.barh()
# mapa braków (wiersze posortowane wg klasy)
kolejnosc = titanic.sort_values("Pclass").index
sns.heatmap(braki.loc[kolejnosc], cbar=False)
```

Braki tworzą **wzór**: kabiny brakuje niemal wyłącznie w 2. i 3. klasie. Mapę braków warto posortować według zmiennej, od której braki mogą zależeć.

Dlaczego brakuje? Trzy mechanizmy

Mechanizm	Znaczenie	Przykład
MCAR całkowicie losowe	brak nie zależy od niczego	czujnik losowo gubi pomiary; kartka ankiety zalana kawą
MAR losowe warunkowo	brak zależy od **innych**, obserwowanych zmiennych	w 3. klasie Titanica rzadziej zapisywano wiek
MNAR nielosowe	brak zależy od **samej** brakującej wartości	osoby o wysokich dochodach nie podają dochodu

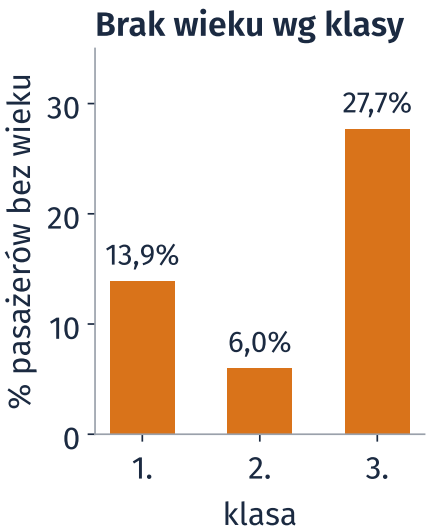
Tylko przy MCAR usunięcie wierszy nie zniekształca wyników. Przy MAR pomagają metody wykorzystujące inne zmienne; MNAR wymaga wiedzy dziedzinowej.

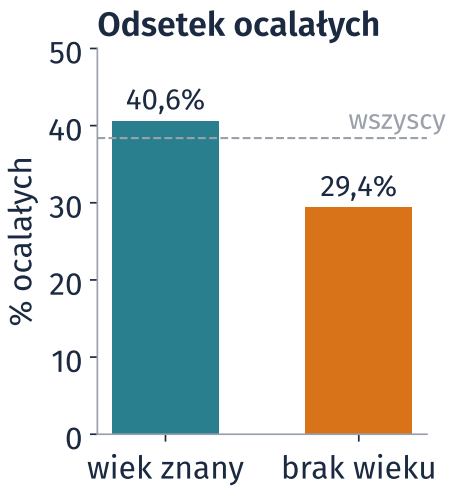
Czy braki wieku na Titanicu są losowe?

```python
brak_wieku = titanic["Age"].isna()

# odsetek braków w każdej klasie
brak_wieku.groupby(
    titanic["Pclass"]).mean()

# odsetek ocalałych
titanic.groupby(brak_wieku)[
    "Survived"].mean()
```





Braki **nie** są losowe (to nie MCAR): w 3. klasie wieku brakuje 4,6 razy częściej niż w 2., a osoby bez wieku rzadziej przeżyły. Usunięcie tych 177 osób **zawyży** odsetek ocalałych.

Jak radzić sobie z brakami?

- **Usunąć** wiersze (lub kolumny) z brakami.
- **Uzupełnić ręcznie**, jeśli znamy prawdziwą wartość.
- **Uzupełnić miarą tendencji centralnej:**
  - **średnią** — cechy liczbowe o w miarę symetrycznym rozkładzie,
  - **medianą** — cechy liczbowe skośne (np. dochód) i cechy porządkowe,
  - **dominantą** (modą) — cechy kategoryczne.
- **Oznaczyć brak** dodatkową kolumną, np. `Age_brak = True` — sam fakt braku bywa informacją.

Uwaga
Najpierw sprawdź, **co** oznacza brak. W zbiorze Ames `NA` w kolumnie `PoolQC` znaczy „brak basenu” — tego nie uzupełnia się średnią.

Usuwanie brakujących wartości: `dropna()`

```python
# Usuń wiersze z DOWOLNĄ brakującą wartością (domyślnie)
titanic.dropna()                        # zostaje 183 z 891 wierszy

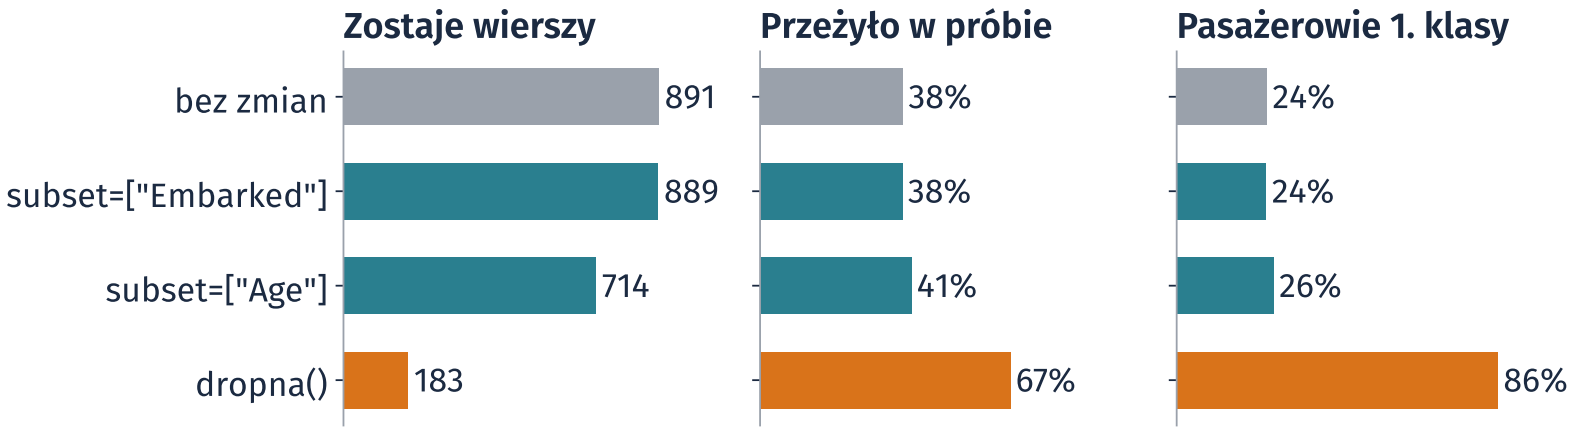
# Usuń wiersze, w których brakuje WSZYSTKICH wartości
titanic.dropna(how="all")               # 891 — takich wierszy nie ma

# Usuń wiersze z brakami tylko w wybranych kolumnach
titanic.dropna(subset=["Age"])          # 714

# Usuń KOLUMNY z brakami
titanic.dropna(axis=1)                  # znikają Age, Cabin i Embarked

# Najpierw usuń „dziurawą” kolumnę, potem wiersze
titanic.drop(columns="Cabin").dropna()  # 712
```

Ile kosztuje usuwanie?



Po `dropna()` zostaje 183 pasażerów: **67%** z nich przeżyło, a **86%** podróżowało 1. klasą (w całym zbiorze: 38% i 24%). To już nie jest próbka pasażerów Titanica.

Usuwaj **kolumnę**, gdy braków jest bardzo dużo i nie niosą informacji; **wiersze** — gdy braków jest mało i są losowe.

Uzupełnianie braków: `fillna()`

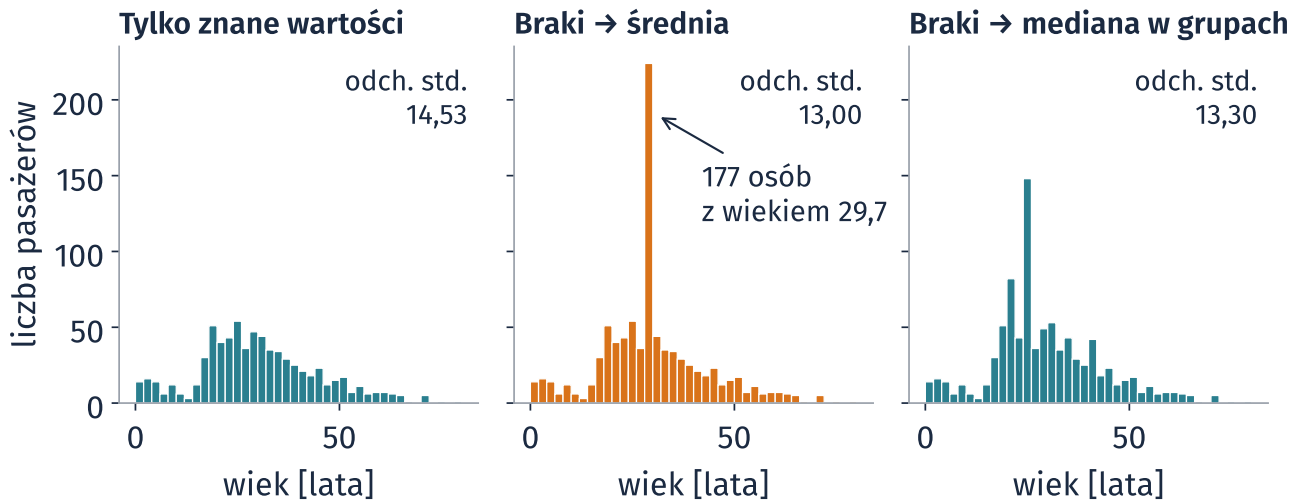
```python
# Wiek — średnia (najprostsza metoda; za chwilę zobaczymy jej koszt)
wiek_srednia = titanic["Age"].fillna(titanic["Age"].mean())    # 29,7

# Gdyby brakowało ceny biletu (rozkład skośny) — mediana
titanic["Fare"].fillna(titanic["Fare"].median())

# Port zaokrętowania (cecha kategoryczna) — dominanta
titanic["Embarked"] = titanic["Embarked"].fillna(
    titanic["Embarked"].mode()[0])                              # "S"
```

Przypisujemy wynik z powrotem do kolumny — w pandas 3.0 nie używamy `inplace=True` na wybranej kolumnie.

Cena prostego uzupełniania



- Po uzupełnieniu średnią **177 pasażerów (20%)** ma dokładnie 29,7 roku — na histogramie powstaje sztuczny „słup”.
- Zmienność jest zaniżona, a korelacje osłabione (wiek–klasa: z −0,37 do −0,33).

> Zawsze porównaj rozkład **przed** i **po** uzupełnieniu.

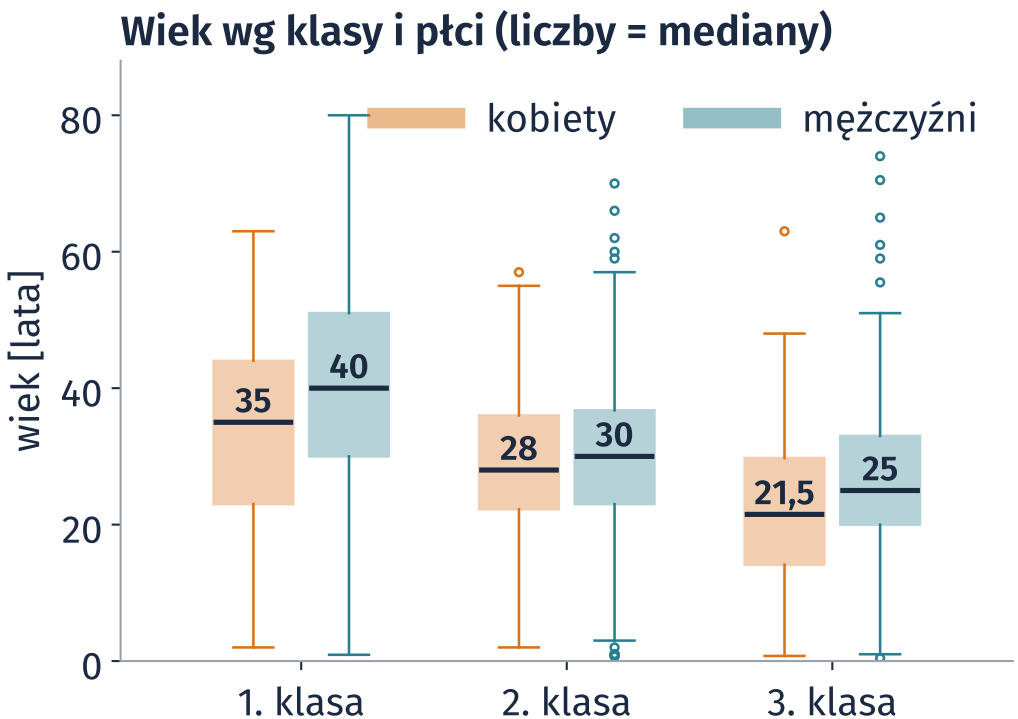
Uzupełnianie w grupach

```python
# flaga braku — przed uzupełnieniem!
titanic["Age_brak"] = titanic["Age"].isna()

mediana_grupy = (titanic
    .groupby(["Pclass", "Sex"])["Age"]
    .transform("median"))

titanic["Age"] = titanic["Age"].fillna(
    mediana_grupy)
```

`transform` zwraca wynik o długości ramki — każdemu wierszowi medianę **jego** grupy.



Zaawansowane uzupełnianie braków

- Uzupełnianie **najbardziej prawdopodobną** wartością przewidzianą przez model:
  - regresja,
  - drzewa decyzyjne,
  - algorytm k najbliższych sąsiadów (KNN).
- Uzupełnianie średnią lub medianą **spłaszcza rozkład** i zaniża zmienność — modele uwzględniają zależności między cechami.

Titanic — nasze decyzje

Kolumna	Braki	Propozycja
`Cabin`	77,1%	nie uzupełniamy numeru kabiny — tworzymy cechę `ma_kabine`: przeżyło ok. 67% osób ze znaną kabiną i 30% bez niej
`Age`	19,9%	mediana w grupach (klasa × płeć) + flaga `Age_brak`; ewentualnie `IterativeImputer`
`Embarked`	2 wiersze	dominanta (`"S"`) albo usunięcie 2 wierszy

Pytanie do sali

Czy dla `Cabin` brak to MCAR, MAR czy MNAR? (Wskazówka: mapa braków na początku podrozdziału.)

Ściągawka: brakujące wartości

Diagnoza

1. Policz braki (`isna().sum()`).
2. Znajdź braki „w przebraniu”.
3. Narysuj mapę braków.
4. Sprawdź, czy braki zależą od innych cech.

Decyzja

1. Mało i losowo → usuń wiersze.
2. Bardzo dużo → usuń kolumnę lub zrób flagę.
3. Inaczej → uzupełnij (grupy, model) + flaga.
4. Porównaj rozkład przed i po.

Każdą decyzję **zapisz** — ile wierszy usunięto, czym uzupełniono i dlaczego.